

Vad ska vi kunna till tentan?

1 Skilja på histogram för fördelningar-
diskret. Geometrisk, binomial

kontinuerlig. \uparrow \downarrow
(gamma) normal

2. Korrelation, varians/kovarians

pearson letar bara efter linjära förhållanden!

3. boxplots, probplots

Jämför mot normalfördelning. Hjälper att avgöra om lin. reg. är lämpligt.

4. Väntevärde, varians, standardavvikelse

$$E[X], \quad E[(X-\mu)^2], \quad \sqrt{\text{Var} X}$$

Dessa är deskriptiva mått; även kända

som moment. $\sigma = \sqrt{\text{Var} X}$, standardavvikelsen

är en sorts förenkling av $\sigma^2 = \text{Var} X$.

5. Sannolikheter, fördelningar

$f(x) = P[X=x]$ sannolikhetsfunktion

$F(x) = P[X \leq x]$ fördelningsfunktion

6. Två definitioner av sannolikhet

relativ frekvens (stickprov): $P[A] = \frac{f}{n}$

klassisk sannolikhet (populationen): $P[A] = \frac{n(A)}{n(S)}$

$\{1, 2, 3, 4, 5, 6, 6, 7, 8, 10\}$

$P[A=9] = 0$ enligt relativ frekvens.

7. Regression

Förklaringsgrad: $R^2 = \frac{SSR}{S_{yy}}$, $0 \leq R^2 \leq 1$

Total varians i y
kan delas upp enligt

$$S_{yy} = SSE + SSR$$

$$(TSS = RSS + SSR)$$

R^2 mäter "hur mycket" av

datan som regressionen förklarar.

Framförallt ger R^2 en god indikation för vilken konfidensnivå vi skall välja.

8 Lin. reg. forställning

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_d X_d$$

Interaktions effekter och linjärisering:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 \quad (1)$$

$$f(\alpha_1, \alpha_2, \alpha_3) = \beta_0 + \beta_1 \alpha_1 + \beta_2 \alpha_2 + \beta_3 \alpha_3$$

$$f(x_1, x_2, x_1 x_2) = (1)$$

Enkla fördelningar

$$E[X] = \sum_x x f(x)$$

$$A, B \sim X$$

$$E[A+B] = \sum_x (x_1 + x_2) f(x)$$

$$x_1 \in A$$

$$x_2 \in B$$

Gemensamma fördelningar

$f_{xy}(x, y)$

sannolikhetsfunktion

Givet:

$$E[X + Y] = \sum_x \sum_y (x + y) f(x, y)$$

$$E[X] = \sum_x \sum_y x f(x, y)$$

Visa att $E[X+Y] = E[X] + E[Y]$
givet en gemensamfördelning (X, Y) .

Notera att

$$\checkmark E[X] = \sum_x \sum_y x f(x, y)$$

$$\checkmark E[Y] = \sum_x \sum_y y f(x, y)$$

dä gäller

$$\begin{aligned} E[X+Y] &= \sum_x \sum_y (x+y) f_{XY}(x, y) \\ &= \sum_x \sum_y \underset{\uparrow}{x} f(x, y) + \sum_x \sum_y \underset{\uparrow}{y} f(x, y) = \underline{E[X]} + \underline{E[Y]} \end{aligned}$$

9. Signifikans (och hypotesprövning)

En sorts hypotesprövning.

tex.

null-hypotes:

$$H_0: \beta = 0$$

dvs alla $\beta_i = 0$

$$\frac{SSR/d}{s^2} \sim F_{d, n-d-1}$$

ensidigt: sf

$$H_0: \beta_i = 0$$

dvs en viss parameter är 0.

$$\frac{\hat{\beta}_i}{\sqrt{c_{ii}}} \sim X \quad \text{okänd fördelning.}$$

om H_0 är sann


$$sf \sim T_{n-d-1}$$

tväsidigt test: $p > 2 \cdot \min(\text{idf}, sf)$

10. Konfidenzintervall

$$\bar{X} \pm Z_{\alpha/2} (\sigma / \sqrt{n}) \quad (\text{för medlet})$$

Om σ och μ är kända!



$Z_{\alpha/2}$ hittar vi med `stats.standard_normal.ppf($\alpha/2$)`
eller `normal.ppf($\alpha/2$, 0, 1)`

$100(1-\alpha)\%$ konfidenzintervall

t.ex. 95% $\rightarrow \alpha = 0.05$, $\alpha/2 = 0.025$

Om σ och μ är obärda

$$\bar{X} \pm t_{\alpha/2} (S/\sqrt{n}) \quad (\text{för medlet})$$

men! fortfarande antagande om $X \sim N(\sigma, \mu)$

För multipel lin. reg. Välj först α !

$$\hat{\beta}_i \pm t_{\alpha/2} S \sqrt{c_{ii}}$$
