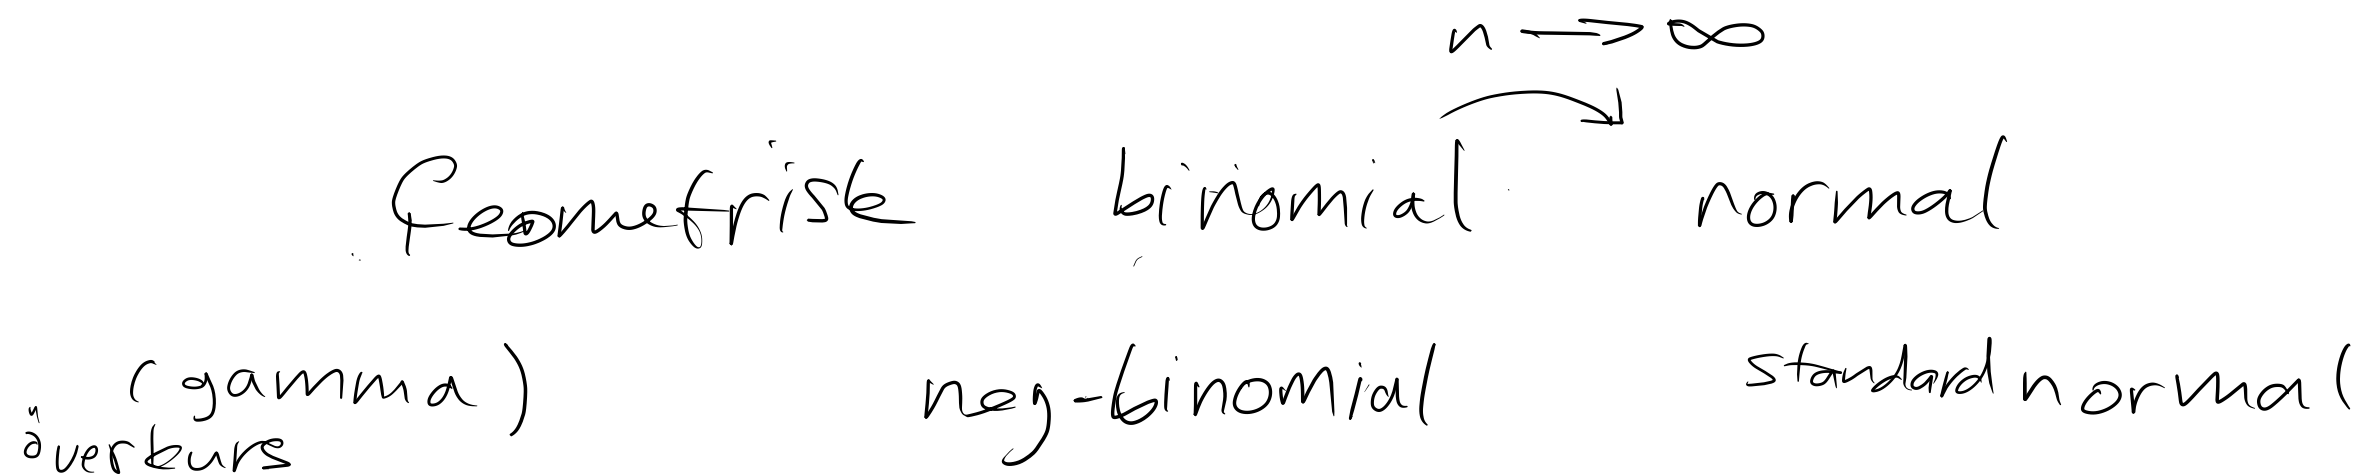


Vad skall ni kunna till tentan (hittills)?

1. Skilja på fördelningar via histogram (öven kumulativa)



2. korrelation, kovarians

pearson r - letar bara efter linjära förhållanden
och antar att responsvariabeln är
normal fördelad.

3. boxplots, probplot

jämför mot normalfördelning - hjälper i avgörandet om lin. reg. metoder är lämpliga.

4. Väntevärde, varians, standard avvikelse

$$E[X] \quad E[(x-\mu)^2] \quad \sqrt{\text{Var } X}$$

Dessa är deskriptiva mått, även kallade momenten.

$\sigma = \sqrt{\text{Var } X}$ är en sorts ytterligare förenkling av andra momentet (som strikt sett bara är $E[X^2]$).

5. Sannolikheter och fördelningar

$$f(x) = P[X=x] \quad \text{sannolikhetsfunktion}$$

$$F(x) = P[X \leq x] \quad \text{fördelningsfunktion}$$

6. Två definitioner av sannolikhet:

relativ frekvens (stickprov): $P[A] = \frac{f}{n}$

Klassisk sannolikhet (population): $P[A] = \frac{n(A)}{n(S)}$

not: $[1, 2, 3, 4, 5, 6, 6, 7, 8, 10]$

relativt: $P[A=9] = 0$, $P[A=6] = \frac{2}{10} = 0.2$

7. Regressioner

Förklaringsgrad: $R^2 = \frac{SSR}{S_{yy}}$ ($TSS = RSS + SSR$)

R^2 mäter "hur mycket" av datan som regressionen förklarar. Ger en god indikation på vilken konfidensnivå vi borde välja.

8. Enkla fördelningar:

$$E[X] = \sum_x x f(x)$$

9. Gemensamma fördelningar

$f_{xy}(x, y)$ sannolikhetsfunktion

$$E[X] = \sum_x \sum_y x f(x, y)$$

$$E[Y] = \sum_x \sum_y y f(x, y)$$

$$E[\lambda X + \mu Y] = \lambda E[X] + \mu E[Y]$$

$$\begin{aligned} E[X+Y] &= \sum_x \sum_y (x+y) f_{xy}(x, y) \\ &= \sum_x \sum_y x f_{xy}(x, y) + \sum_x \sum_y y f_{xy}(x, y) = E[X] + E[Y] \end{aligned}$$

10. Signifikans (och hypotesprövning)

$$H_0: \beta = 0$$

dvs alla $\beta_i = 0$

$$\frac{SSR/d}{S^2} \sim F_{d, n-d-1}$$

ensidigt test: stats. f. sf
(survival function)

$$H_0: \beta_i = 0$$

$$\frac{\hat{\beta}_i}{S \sqrt{c_{ii}}} \sim X \text{ skind fördelning}$$
$$\sim T_{n-d-1}$$

två-sidigt test

$$p = 2 \cdot \min(cdf, sf)$$


11. Konfidsensintervall

Om μ och σ är kända så är

$$\bar{X} \pm Z_{\alpha/2} (\sigma / \sqrt{n}) \quad \text{ett } 100(1-\alpha)\% \text{ KI för medlet}$$

$Z_{\alpha/2}$ hittar vi med stats. Standard-normal. ppf ($\alpha/2$)
stats.normal($\alpha/2, 0, 1$)

$$\text{tex: } 95\% \text{ KI} \rightarrow \alpha = 0.05 \quad \alpha/2 = 0.025$$



Om σ , μ är kända

$\bar{X} \pm t_{\alpha/2} (S/\sqrt{n})$ är ett $100(1-\alpha)\%$ KI för medlet.

men! fortfarande antagande om att $Y \sim N(\mu, \sigma)$
där S är en rättvis skattning av σ .

För prediktorer/parametrar!

$$\hat{\beta}_i \pm t_{\alpha/2} S \sqrt{c_{ii}}$$

Välj först α !

12.
$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$$

Om interaktionseffekten är signifikant
(dvs $H_0: \beta_3 = 0$ avvisas genom test)

så skall β_1 och β_2 inkluderas i modellen
oavsett deras signifikans.

Hierarkiprincipen