


Skattning (Estimation)

$$\mathbb{E}[X] = \mu \Rightarrow \bar{X}$$

$$\text{Var } X = \sigma^2 \Rightarrow S^2$$

Skattare (estimators)

$\hat{\mu}$ (räglvisa skattare)
 $\hat{\sigma}$



Felern runt regressionslinjen kallas (kvadrerade)

SSE (sum of square errors)

En regression vill minimera SSE!

$$SSE = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

$$\frac{\partial \text{SSE}}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0$$

$$\frac{\partial \text{SSE}}{\partial b_1} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) x_i = 0$$

$$nb_0 + b_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$b_0 \sum_{i=1}^n x_i + b_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$b_1 = \frac{n \sum_{i=1}^n x_i y_i - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}$$

$$b_0 = \bar{y} - b_1 \bar{x}$$

$$\hat{b} = (A^T A)^{-1} A^T y$$

$$X = \begin{pmatrix} \beta_0 & \downarrow \\ 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \\ \vdots & \end{pmatrix}$$

$$Y = X\beta + E \iff Y = \beta_0 + \beta_1 X + E$$

$$\frac{d}{dx} kx + m = k \iff \frac{d}{dx} kx^1 + m = 1 \cdot k x^0 + 0 = k$$

Power law for derivatives

$$\frac{d}{dx} x^a = a x^{a-1}$$

När vi gjort regression så har vi en skattning
av medlet i γ givet X

$$\hat{\mu}_{Y|X} = \beta_0 + \beta_1 X$$

Test statistiker

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

För hypoteser:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 > 0$$

Högersidigt test
(right-tailed)

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 < 0$$

Vänstersidigt test
(left-tailed)

"Inference on slope" (inferens på lutningen)

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

$$T_{n-2} = \frac{\beta_1}{s/\sqrt{S_{xx}}}$$


s = stickprovs avvikelsen

S_{xx} = Variabilitet i X

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Konfidens intervall:


$$\beta_1 \pm t_{\alpha/2} s \sqrt{S_{xx}}$$



$$\hat{\mu}_{\text{1x}} \pm t_{\alpha/2} \frac{s \sqrt{\frac{1}{n} + \frac{(1-\bar{x})^2}{s^2}}}{s_{\text{ta}}}$$

Räkna ut ovanstående för hela datamängden :

$$\{L_1, L_2\}$$




Värde regression: förutsäg ett numeriskt värde.

Klassificering: förutsäg en egenskap

Maximum Likelihood estimation

$$\hat{\theta} = \operatorname{argmax} L(\theta; y)$$



För n gemensamma fördelningar (deras parametrar θ)

$$f_n(y|\theta) = \prod_{k=1}^n f_k(y_k; \theta) \Rightarrow L(\theta; y)$$

detta är ett maximeringsproblem, en lossfunktion är dock ett minimeringsproblem: $l_k = -y_k \ln p_k - (1-y_k) \ln (1-f_k)$

$$L = \prod_{k: y_k=1} p_k \prod_{k: y_k=0} (1-p_k)$$

För komplicerade gemensamma fördelningar

kan vi inte alltid hitta vettiga former för likelihood-funktioner,

Då vänder vi oss i ML till

Stochastic Gradient Descent